

## ✎ Importamos las librerías que vamos a utilizar

```
from google.colab import drive
drive.mount('/content/drive')
```

↗ Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force\_remount=True)

```
import pandas as pd
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import confusion_matrix
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA
from yellowbrick.cluster import KElbowVisualizer, SilhouetteVisualizer
import warnings
# Ignorar todos los mensajes de advertencia
warnings.filterwarnings("ignore")
```

## ✎ Importamos el dataset para el practico

```
#####
##INICIO DE LA PARTE A COMPLETAR
#####

#Aplique la ruta correcta utilizando la ubicacion en donde alojo el archivo "data.csv"
#ruta_archivo = r'.\data\data.csv'
df = pd.read_csv('/content/drive/MyDrive/Colab Notebooks/proyecto_aprendizaje_no_supervisado/data.csv')

print(df.shape)
#####
##FIN DE LA PARTE A COMPLETAR
#####

# Leer el archivo CSV en un DataFrame
#df = pd.read_csv(ruta_archivo)

#print(df.shape)

# Configurar pandas para mostrar todas las columnas
pd.set_option('display.max_columns', None)

# Mostrar el conjunto de datos
df.sample(5)
```

↗ (569, 32)


	id	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity
<b>306</b>	89344	B	13.20	15.82	84.07	537.3	0.08511	0.05251	0.0
<b>14</b>	84667401	M	13.73	22.61	93.60	578.3	0.11310	0.22930	0.2
<b>476</b>	911654	B	14.20	20.53	92.41	618.4	0.08931	0.11080	0.0
<b>399</b>	904357	B	11.80	17.26	75.26	431.9	0.09087	0.06232	0.0
<b>350</b>	899187	B	11.66	17.07	73.70	421.0	0.07561	0.03630	0.0

A continuacion graficaremos los datos, para evaluar cuantos tumores son benignos y malignos, la idea de este practico,

- ✎ es evaluar si aplicando un algoritmo de CLUSTERING, podemos encontrar 2 agrupaciones o mas, que nos permitan identificar si los tumores son benignos o malignos, de acuerdo al cluster que pertenezcan.

```
# Crear un gráfico de conteo para la variable "diagnosis"
plt.figure(figsize=(6, 4))
ax = sns.countplot(x='diagnosis', data=df, palette='Set1')
ax.set(xlabel='Diagnosis', ylabel='Count', title='Count of Benign and Malignant Tumors')
plt.show()
```

```
# Obtener y mostrar el número de casos benignos (B) y malignos (M)
B, M = df['diagnosis'].value_counts()
print('Number of Benign (B): ', B)
print('Number of Malignant (M): ', M)
```



```
Number of Benign (B): 357
Number of Malignant (M): 212
```


- ✓ Como se observa la mayoría de las muestras, son tumores Benignos (357 casos) y (212 casos) son malignos, lo cual demuestra que es un dataset balanceado.

Remplazamos el TARGET B y M, por 0 y 1 respectivamente, para mas adelante realizar una Confusion Matrix y evaluar los resultados, de forma simple. A continuacion eliminamos las 2 columnas ID ya que no es un campo relevante para el algoritmo y el campo diagnosis que es el TARGET, o campo que utilizaremos para contrastar resultados, el foco de este practico es confirmar si los clusteres detectados permiten separar los 2 tipos de tumores.

```
# Convertir las etiquetas de "diagnosis" a números (0 y 1) para mas adelante hacer una Confusion Matrix
df['diagnosis'] = df['diagnosis'].map({'B': 0, 'M': 1})
```

```
# Eliminar las columnas "diagnosis" e "id" del conjunto de características, solo dejamos las variables sin ningun target que per
X = df.drop(['diagnosis', 'id'], axis=1)
```

```
X.sample(5)
```



	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	s
427	10.80	21.98	68.79	359.9	0.08801	0.05743	0.03614	0.014040	
294	12.72	13.78	81.78	492.1	0.09667	0.08393	0.01288	0.019240	
144	10.75	14.97	68.26	355.3	0.07793	0.05139	0.02251	0.007875	
238	14.22	27.85	92.55	623.9	0.08223	0.10390	0.11030	0.044080	
186	18.31	18.58	118.60	1041.0	0.08588	0.08468	0.08169	0.058140	

- ✓ Estandarizamos las características, para mas adelante aplicar K-Means y que todas esten expresadas en la misma escala

```
# Estandarizar las características para el K-Means
#Escalar X y generar el vector llamado X_scaled
```

```
scaler = StandardScaler()
```

```
#####
##INICIO DE LA PARTE A COMPLETAR
#####
```

```
#Aplicar funcion para Escalar X y asginar el resultado a X_scaled
X_scaled = scaler.fit_transform(X)
```

```
#####
##FIN DE LA PARTE A COMPLETAR
#####
```

```
#Visualizamos el vector con los datos escalados
print(X_scaled[:2])
```

```
[[ 1.09706398e+00 -2.07333501e+00  1.26993369e+00  9.84374905e-01
  1.56846633e+00  3.28351467e+00  2.65287398e+00  2.53247522e+00
  2.21751501e+00  2.25574689e+00  2.48973393e+00 -5.65265059e-01
  2.83303087e+00  2.48757756e+00 -2.14001647e-01  1.31686157e+00
  7.24026158e-01  6.60819941e-01  1.14875667e+00  9.07083081e-01
  1.88668963e+00 -1.35929347e+00  2.30360062e+00  2.00123749e+00
  1.30768627e+00  2.61666502e+00  2.10952635e+00  2.29607613e+00
  2.75062224e+00  1.93701461e+00]
 [ 1.82982061e+00 -3.53632408e-01  1.68595471e+00  1.90870825e+00
 -8.26962447e-01 -4.87071673e-01 -2.38458552e-02  5.48144156e-01
  1.39236330e-03 -8.68652457e-01  4.99254601e-01 -8.76243603e-01
  2.63326966e-01  7.42401948e-01 -6.05350847e-01 -6.92926270e-01
 -4.40780058e-01  2.60162067e-01 -8.05450380e-01 -9.94437403e-02
  1.80592744e+00 -3.69203222e-01  1.53512599e+00  1.89048899e+00
 -3.75611957e-01 -4.30444219e-01 -1.46748968e-01  1.08708430e+00
 -2.43889668e-01  2.81189987e-01]]
```


✓ A continuacion realizaremos varias iteraciones con el algoritmo K-means, para poder visualizar con el metodo de elbow, cual es el mejor valor de K, para este conjunto de datos.

```
# Instantiate the clustering model and visualizer
seed = 0
```

```
km = KMeans(init = 'k-means++'
            , max_iter=500
            , n_init=10
            , random_state=seed)
```

```
visualizer = KElbowVisualizer(km, k=(1,10))
```

```
visualizer.fit(X_scaled)      # Fit the data to the visualizer
visualizer.show()             # Finalize and render the figure
```



```
<Axes: title='center': 'Distortion Score Elbow for KMeans Clustering', xlabel='k', ylabel='distortion score'>
```

- ✓ Aplicamos el metodo de ELBOW, y el resultado es que recomienda utilizar un valor de  $k=3$ , sin embargo visiblemente el codo se marca mejor con un  $k=2$ , ademas como ya sabemos de antemano que hay 2 tipos de tumores benignos y malignos, vamos a trabajar y considerar 2 grandes grupos, para mas adelante contrastar, si los grupos identificados por el algoritmo, estan alineados a los 2 tipos de tumores.


A continuacion vamos a aplicar el metodo de la silueta para entender que valor de  $K$  es mas conveniente. Esperemos que sean 2.

```
nclusters = 2
seed = 0

model = KMeans(n_clusters=nclusters
               , init = 'k-means++'
               , max_iter=500
               , n_init=10
               , random_state=seed)

visualizer = SilhouetteVisualizer(model)

visualizer.fit(X_scaled)    # Fit the data to the visualizer
visualizer.show()          # Draw/show/show the data
```




```
<Axes: title={'center': 'Silhouette Plot of KMeans Clustering for 569 Samples in 2 Centers'}, xlabel='silhouette coefficient values' ylabel='cluster label'>
```

```
nclusters = 3
seed = 0
```

```
model = KMeans(n_clusters=nclusters
               , init = 'k-means++'
               , max_iter=500
               , n_init=10
               , random_state=seed)
```

```
visualizer = SilhouetteVisualizer(model)
```

```
visualizer.fit(X_scaled) # Fit the data to the visualizer
visualizer.show()       # Draw/show/show the data
```



```
<Axes: title={'center': 'Silhouette Plot of KMeans Clustering for 569 Samples in 3 Centers'}, xlabel='silhouette coefficient values' ylabel='cluster label'>
```

- ✓ Luego de aplicar el metodo de la SILUETA confirmamos que 2 clusteres, es lo adecuado. Confirmando el analisis visual del metodo de elbow.

A conitnuacion aplicaremos K-means, y luego una transformacion simple, ya que K-means, nomenclra aleatoreamente los clusters detectados. Necesitamos forzar a que el CLUSTER MAYORITARIO el de mayor cantidad de elementos se le asigne el valor 0 y al minoritario 1. Para ir en linea, con el campo TARGET, ya que como confirmamos al inicio del analisis, identificamos que el grupo minoritario de tumores, son los del tipo maligno, por lo tanto le asignaremos el valor 1. Para que luego cuando utilicemos la matriz de confusion, se pueda considerar una coincidencia cuando ambos valores sean 1 o 0.

```
#####
##INICIO DE LA PARTE A COMPLETAR
#####
X_scaled = scaler.fit_transform(X)

# Crear el modelo de K-Means con 2 clusters (benigno y maligno) ademas tiene mejor puntaje de SILUETA
# Utilizar kMeans con la variables n_clusters=2 a "X_scaled" y alojar el resultado en "df['cluster']" utilizando el metodo fit_r
kmeans_model = KMeans(n_clusters=2, random_state=42)
df['cluster'] = kmeans_model.fit_predict(X_scaled)

#####
##FIN DE LA PARTE A COMPLETAR
#####

# Obtener el tamaño de cada cluster
tamano_clusters = df['cluster'].value_counts()

# Determinar el cluster mayoritario
cluster_mayoritario = tamano_clusters.idxmax()

# Asignar etiquetas basadas en el cluster mayoritario
df['cluster'] = df['cluster'].apply(lambda x: 0 if x == cluster_mayoritario else 1)

# Crear un gráfico de barras para la distribución de clusters
plt.figure(figsize=(6, 4))
ax = sns.countplot(x='cluster', data=df, palette='Set1')

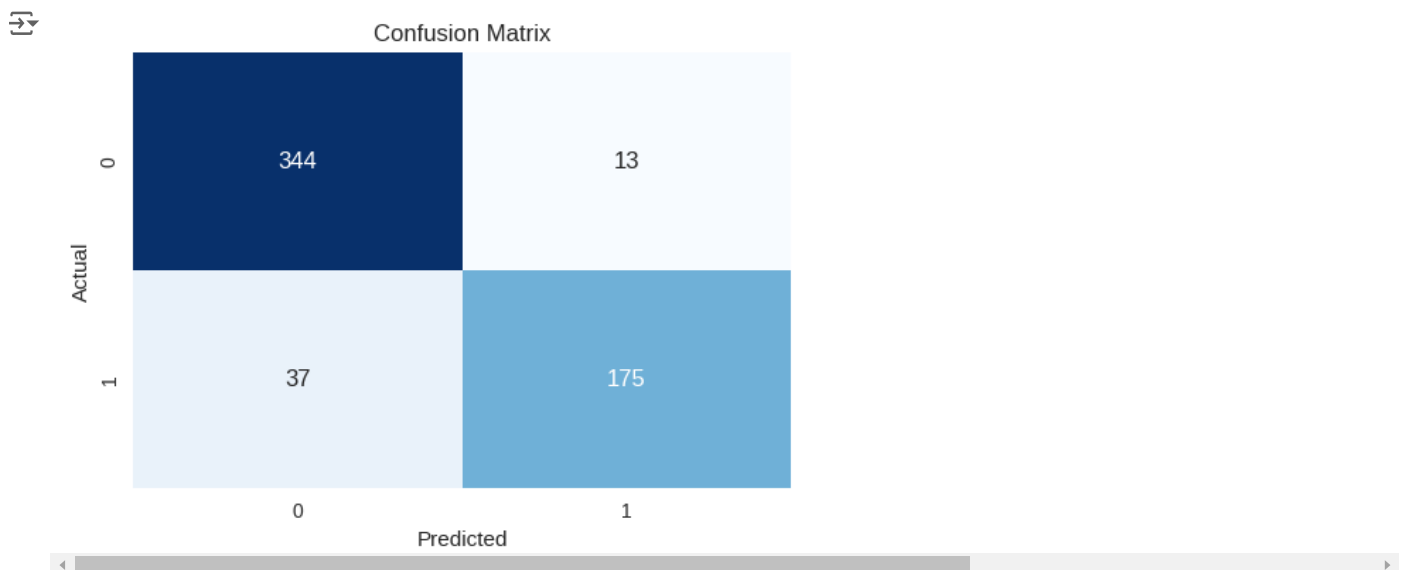
# Agregar etiquetas con los números correspondientes a cada barra
for p in ax.patches:
    ax.annotate(f'{p.get_height()}', (p.get_x() + p.get_width() / 2., p.get_height()),
                ha='center', va='center', fontsize=10, color='black', xytext=(0, 5),
                textcoords='offset points')

plt.xlabel('Cluster')
plt.ylabel('Count')
plt.title('Distribution of Clusters')
plt.show()
```



```
# Crear una matriz de confusión para comparar con el campo "diagnosis"
conf_matrix = confusion_matrix(df['diagnosis'], df['cluster'])

# Mostrar la matriz de confusión como un mapa de calor
plt.figure(figsize=(6, 4))
sns.heatmap(conf_matrix, annot=True, fmt='g', cmap='Blues', cbar=False)
plt.xlabel('Predicted')
plt.ylabel('Actual')
plt.title('Confusion Matrix')
plt.show()
```



La matriz de Confusion, presenta un MUY BUEN resultado, la mayoría de los casos están bien clasificados, lo que indica que cada tipo de tumor, tiene características muy distintivas que hacen que cada tipo de tumor sea muy identificable y pertenezca a un cluter específico.

A continuación aplicaremos PCA para poder visualizar en un gráfico de 2 dimensiones los puntos, y poder pintar con colores diferentes cada cluster.

```
#####
##INICIO DE LA PARTE A COMPLETAR
#####
X_scaled = scaler.fit_transform(X)
# Aplicar PCA para reducir la dimensionalidad a 2 componentes, para mejorar el entrenamiento y visualizar clusters
# Utilizar la libreria PCA con (n_components=2), aplicarlo a "X_scaled" y alojar el resultado en "X_pca"

# Aplicar funcion para Escalar X y asignar el resultado a X_scaled
X_scaled = scaler.fit_transform(X)

# Crear el modelo de K-Means con 2 clusters (benigno y maligno) ademas tiene mejor puntaje de SILUETA
```

```
# Utilizar kMeans con la variables n_clusters=2 a "X_scaled" y alojar el resultado en "df['cluster']" utilizando el metodo fit_r
kmeans_model = KMeans(n_clusters=2, random_state=42)
df['cluster'] = kmeans_model.fit_predict(X_scaled)

# Aplicar PCA para reducir la dimensionalidad a 2 componentes, para mejorar el entrenamiento y visualizar clusters
# Utilizar la libreria PCA con (n_components=2), aplicarlo a "X_scaled" y alojar el resultado en "X_pca"
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)
```

```
#####
##FIN DE LA PARTE A COMPLETAR
#####
```

```
# Varianza explicada por cada componente
explained_variance = pca.explained_variance_ratio_
print("Varianza explicada por cada componente principal:", explained_variance)
```


```
↗ Varianza explicada por cada componente principal: [0.44272026 0.18971182]
```

- Se puede observar que la varianza capturada con 2 componentes principales es del 63% un valor bastante bajo, quiere decir que no
- ✓ representan fielmente a las originales, de todos modos vamos a visualizar los puntos. como valor agregado podrian utilizar un grafico 3D para lograr una mayor captura de varianza, y tener una visualizacion de los puntos mas confiable.

```
# Crear un DataFrame con las nuevas variables PCA
df_pca = pd.DataFrame(data=X_pca, columns=['PCA1', 'PCA2'])

# Añadir la columna "diagnosis" al DataFrame PCA
df_pca['diagnosis'] = df['diagnosis']

# Visualizar el resultado en un scatter plot
plt.figure(figsize=(8, 6))
sns.scatterplot(x='PCA1', y='PCA2', hue='diagnosis', data=df_pca, palette='Set1')
plt.title('PCA - Breast Cancer Dataset')
plt.show()
```



- ✓ A pesar del bajo grado de explicabilidad, se visualizan 2 clusters separados por una linea IMAGINARIA, no se detecta un espacio que los diferencie claramente.



```
# Seleccionar las nuevas características PCA para clustering
X_pca_for_clustering = df_pca[['PCA1', 'PCA2']]

#####
##INICIO DE LA PARTE A COMPLETAR
#####
X_scaled = scaler.fit_transform(X_pca_for_clustering)
# Crear el modelo de K-Means con 2 clusters
# Utilizar kMeans con la variables n_clusters=2 a "X_pca_for_clustering" y alojar el resultado en "df_pca['cluster_pca']" utiliz
kmeans_model = KMeans(n_clusters=2, random_state=42)
df['cluster'] = kmeans_model.fit_predict(X_scaled)
# La idea es aplicar nuevamente K-means como antes, pero en vez utilizarlo en "X_scaled", lo aplicaremos directamente en "X_pca_
# 2 componentes luego de aplicar PCA, buscando mejorar los resultados y tiempos de ejecucion.
# Aplicar PCA para reducir la dimensionalidad a 2 componentes, para mejorar el entrenamiento y visualizar clusters
# Utilizar la libreria PCA con (n_components=2), aplicarlo a "X_scaled" y alojar el resultado en "X_pca"
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)
# Crear el modelo de K-Means con 2 clusters
# Utilizar kMeans con la variables n_clusters=2 a "X_pca_for_clustering" y alojar el resultado en "df_pca['cluster_pca']" utiliz
# La idea es aplicar nuevamente K-means como antes, pero en vez utilizarlo en "X_scaled", lo aplicaremos directamente en "X_pca_
# 2 componentes luego de aplicar PCA, buscando mejorar los resultados y tiempos de ejecucion.
kmeans_pca_model = KMeans(n_clusters=2, random_state=42)
#df_pca = pd.DataFrame(X_pca, columns=['PCA1', 'PCA2'])
df_pca = pd.DataFrame(X_pca, columns=['PCA1', 'PCA2'])
df_pca['cluster_pca'] = kmeans_pca_model.fit_predict(X_pca)

#####
##FIN DE LA PARTE A COMPLETAR
#####

# Obtener el tamaño de cada cluster
tamano_clusters = df_pca['cluster_pca'].value_counts()

# Determinar el cluster mayoritario
cluster_mayoritario = tamano_clusters.idxmax()


# Asignar etiquetas basadas en el cluster mayoritario
df_pca['cluster_pca'] = df_pca['cluster_pca'].apply(lambda x: 0 if x == cluster_mayoritario else 1)

# Mostrar el resultado
print(df_pca['cluster_pca'].value_counts())
```

```
cluster_pca
0      377
1      192
Name: count, dtype: int64
```

- Aplicamos nuevamente clustering, pero ahora en vez de trabajar con todo el dataset escalado, directamente utilizamos las 2 componentes principales identificadas, con esto queremos validar si obtenemos un mejor resultado, y en menor tiempo de ejecución. Para validar si es verdad las ventajas que promete PCA, a la hora de entrenar algoritmos. Como punto extra podría realizar mediciones del tiempo de entrenamiento de ambos algoritmos, entrenando un modelo k-means con 2 componentes principales vs trabajar con las variables originales que son muchas mas.

```
# Visualizar el resultado en un scatter plot con los clusters de K-Means
plt.figure(figsize=(8, 6))
sns.scatterplot(x='PCA1', y='PCA2', hue='cluster_pca', data=df_pca, palette='Set1', legend='full')
plt.title('K-Means Clustering after PCA')
plt.show()
```



```
df_pca.sample(20)
```



	PCA1	PCA2	cluster_pca
491	-1.700615	-0.980110	0
146	1.755655	1.209931	1
233	-1.842215	0.400886	1
274	-1.289632	-0.287450	0
503	-2.776326	1.251568	1
148	-0.124240	-0.155047	0
270	-0.920300	-1.564288	0
241	-0.348829	-1.385816	0
392	-0.016594	1.182952	1
213	0.775545	1.196411	1
38	-1.268181	-0.663394	0
398	0.165393	-1.034429	0
291	-0.292114	-0.206615	0
183	0.425172	-0.634769	0
35	-0.358998	0.685112	1
234	0.783153	-0.922476	0
540	1.090427	-0.152116	0
502	0.715249	-0.190343	0
515	0.500186	-0.519186	0
10	-1.004867	-0.531257	0

```
# Crear una matriz de confusión para comparar los clusters con el campo "diagnosis"
conf_matrix_pca = confusion_matrix(df_pca['diagnosis'], df_pca['cluster_pca'])
```

```
# Mostrar la matriz de confusión como un mapa de calor
plt.figure(figsize=(6, 4))
sns.heatmap(conf_matrix_pca, annot=True, fmt='g', cmap='Blues', cbar=False)
plt.xlabel('Predicted')
plt.ylabel('Actual')
```

```
plt.title('Confusion Matrix after PCA and K-Means Clustering')
plt.show()
```



```
-----
KeyError                                Traceback (most recent call last)
/usr/local/lib/python3.10/dist-packages/pandas/core/indexes/base.py in get_loc(self, key)
    3804         try:
-> 3805             return self._engine.get_loc(casted_key)
    3806         except KeyError as err:

index.pyx in pandas._libs.index.IndexEngine.get_loc()

index.pyx in pandas._libs.index.IndexEngine.get_loc()

pandas/_libs/hashtable_class_helper.pxi in pandas._libs.hashtable.PyObjectHashTable.get_item()

pandas/_libs/hashtable_class_helper.pxi in pandas._libs.hashtable.PyObjectHashTable.get_item()

KeyError: 'diagnosis'
```

The above exception was the direct cause of the following exception:

```
-----
KeyError                                Traceback (most recent call last)
----- 2 frames -----
/usr/local/lib/python3.10/dist-packages/pandas/core/indexes/base.py in get_loc(self, key)
    3810         ):
    3811             raise InvalidIndexError(key)
-> 3812             raise KeyError(key) from err
    3813         except TypeError:
    3814             # If we have a listlike key, _check_indexing_error will raise

KeyError: 'diagnosis'
```

**T** **B** **I** **<>** **↔** **🖼️** **”** **☰** **⋮** **—** **ψ** **😊** **⋮**

Marca error al generar la matriz de confusion porque la columna (df\_pca['diagnosis'] toma valores Nan cuando se forma el conjunto X en la celdas siguientes:# Convertir las etiquetas de "diagnosis" a números (0 y 1) para mas adelante hacer una Confusion Matrix

```
df['diagnosis'] = df['diagnosis'].map({'B': 0, 'M': 1})
```

# Eliminar las columnas "diagnosis" e "id" del conjunto de características, solo dejamos las variables sin ningun target que permita identificar de antemano que tipo de tumor es

```
X = df.drop(['diagnosis', 'id'], axis=1)
```

El error proviene de una linea que ha sido dada y que yo no tengo que resolver.  
En caso de que lo tenga que resolver yo tendria que transformar todo el codigo original del archivo .ipynb

A partir de aqui ya no se puede continuar, por lo tanto el trabajo no se puede completar.  
si hubiese sabido anticipadamente que se me pediria esto, hubiese cambiado la logica a la hora de resolver el ejercicio.  
He encontrado el defecto pero por el tiempo invertido, enfocado lo que se me pedia no he podido llegar a hacer estos arreglos.  
De aqui para abajo ya marca error.....

Marca error al generar la matriz de confusion porque la columna (df\_pca['diagnosis'] toma valores Nan cuando se forma el conjunto X en la celdas siguientes:# Convertir las etiquetas de "diagnosis" a números (0 y 1) para mas adelante hacer una Confusion Matrix

```
df['diagnosis'] = df['diagnosis'].map({'B': 0, 'M': 1})
```

Eliminar las columnas "diagnosis" e "id" del conjunto de características, solo dejamos las variables sin ningun target que permita identificar de antemano que tipo de tumor es

```
X = df.drop(['diagnosis', 'id'], axis=1)
```

El error proviene de una linea que ha sido dada y que yo no tengo que resolver. En caso de que lo tenga que resolver yo tendria que transformar todo el codigo original del archivo .ipynb

A partir de aqui ya no se puede continuar, por lo tanto el trabajo no se puede completar. si hubiese sabido anticipadamente que se me pediria esto, hubiese cambiado la logica a la hora de resolver el ejercicio. He encontrado el defecto pero por el tiempo invertido, enfocado a lo que se me pedia no he podido llegar a hacer estos arreglos.

De aqui para abajo ya marca error.....



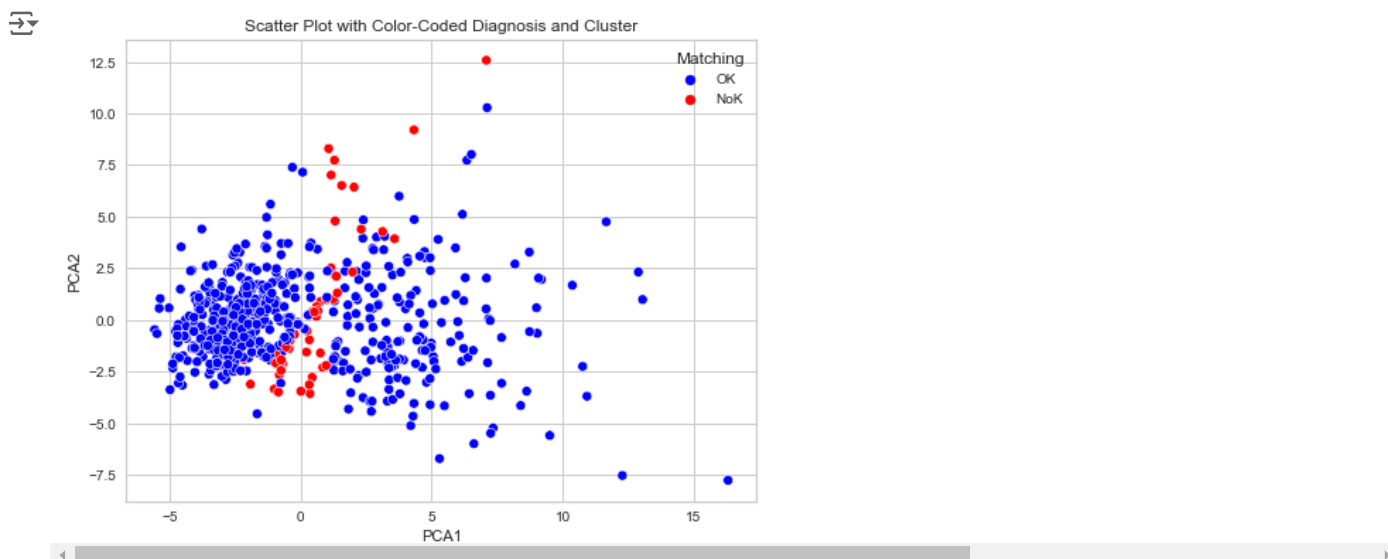
✓ Cuando analizamos la precision con PCA, logramos una MEJORA MINIMA, practicamente es el mismo resultado, en este caso, no logramos una mejora sustancia en el resultado, pero seguramente si se tratara de un volumen muy grande de datos, seria mejor entrenar el modelo con las nuevas variables, ya que el algoritmo logra practicamente el mismo resultado. Por otro lado utilizar 3

componentes podría generar alcanzar un mejor resultado, ya que confirmamos que las 2 componentes principales, no representan con gran fiabilidad a las originales.

```
# Crear un scatter plot
plt.figure(figsize=(8, 6))

# Asignar colores según la lógica dada
colors = df_pca.apply(lambda row: 'OK' if row['diagnosis'] == row['cluster_pca'] else 'NoK', axis=1)

sns.scatterplot(x='PCA1', y='PCA2', data=df_pca, hue=colors, palette=['blue', 'red'], s=50)
plt.xlabel('PCA1')
plt.ylabel('PCA2')
plt.title('Scatter Plot with Color-Coded Diagnosis and Cluster')
plt.legend(title='Matching')
plt.show()
```



En este gráfico marcamos en ROJO los casos mal clasificados, y realmente es algo esperable, ya que son casos que se encuentran en la división de los 2 clusters, por lo tanto, existían grandes posibilidades de que sean mal clasificados, un punto importante aquí, sería evaluar otro método de reducción de dimensionalidad, que separe más los puntos o evaluar otro algoritmo de clustering para confirmar si se arriba a mejores resultados. También se podría evaluar trabajar con más componentes principales, ya que la representatividad de solo 2 componentes es baja. Aquí se compara el TARGET original vs Cluster identificado.

De todos modos considero, que el algoritmo de CLUSTERING logró un RESULTADO EXCELENTE, clasificando la mayoría de los casos de forma correcta de los 569 casos, 516 fueron clasificados correctamente. Logrando una precisión del 90.6%

Lo más interesante de esto, es que el problema encontró una solución utilizando un algoritmo de CLUSTERING, y sería útil en el caso de datos NO ETIQUETADOS. Aquí solo usamos las etiquetas, para que se pueda realizar una comparación entre el resultado obtenido, y una clasificación real.

```
# Aplicar TSNE para reducir la dimensionalidad a 2 componentes, para mejorar el entrenamiento y visualizar clusters
```

```
from sklearn.manifold import TSNE
```

```
#####
##INICIO DE LA PARTE A COMPLETAR
#####
```

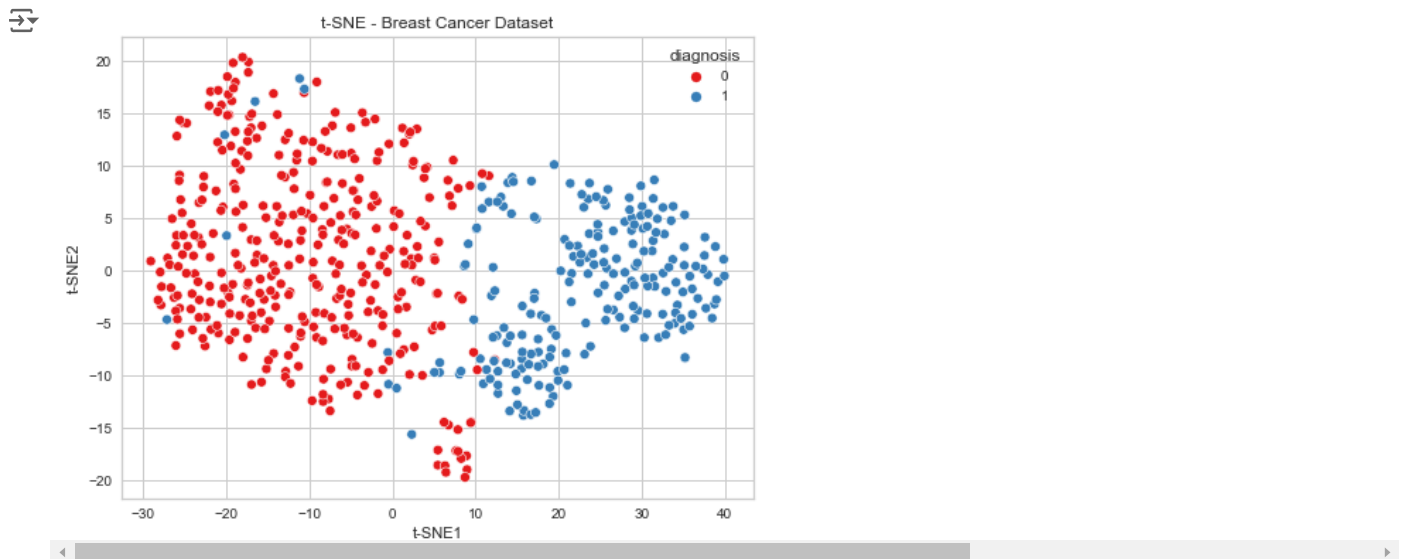
```
# Aplicar t-SNE para reducir la dimensionalidad a 2 componentes, para mejorar el entrenamiento y visualizar clusters, similar a
# Utilizar la librería TSNE con (n_components=2), aplicarlo a "X_scaled" y alojar el resultado en "X_tsne"
```

```
#####
##FIN DE LA PARTE A COMPLETAR
#####
```

```
# Crear un DataFrame con las nuevas variables t-SNE
df_tsne = pd.DataFrame(data=X_tsne, columns=['t-SNE1', 't-SNE2'])

# Añadir la columna "diagnosis" al DataFrame t-SNE
df_tsne['diagnosis'] = df['diagnosis']

# Visualizar el resultado en un scatter plot
plt.figure(figsize=(8, 6))
sns.scatterplot(x='t-SNE1', y='t-SNE2', hue='diagnosis', data=df_tsne, palette='Set1')
plt.title('t-SNE - Breast Cancer Dataset')
plt.show()
```



```
# Seleccionar las nuevas características t-SNE para clustering
X_tsne_for_clustering = df_tsne[['t-SNE1', 't-SNE2']]

# Crear el modelo de K-Means con 2 clusters
kmeans_tsne = KMeans(n_clusters=2, random_state=42)
df_tsne['cluster_tsne'] = kmeans_tsne.fit_predict(X_tsne_for_clustering)

# Obtener el tamaño de cada cluster
tamano_clusters_tsne = df_tsne['cluster_tsne'].value_counts()

# Determinar el cluster mayoritario
cluster_mayoritario_tsne = tamano_clusters_tsne.idxmax()

# Asignar etiquetas basadas en el cluster mayoritario
df_tsne['cluster_tsne'] = df_tsne['cluster_tsne'].apply(lambda x: 0 if x == cluster_mayoritario_tsne else 1)

# Crear una matriz de confusión para comparar los clusters con el campo "diagnosis"
```