# Actividad Semana 1

# Análisis problema de clasificación con Deep Learning

Natalia Camarano
Semana 1: Redes convolucionales y otros tipos de redes
IEBS

---

```
import tensorflow as tf
import numpy as np

# Para mostrar gráficas
import matplotlib.pyplot as plt
%matplotlib inline

# Anaconda fixing problem
import os
os.environ['KMP_DUPLICATE_LIB_OK']='True'


from google.colab import drive
drive.mount('/content/drive')
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).
```

En esta actividad vamos a seguir familiarizándonos con la herramienta *TensorFlow* pero esta vez para redes convolucionales, para ello seguiremos utilizando el dataset de imágenes a color visto en clase.

## CIFAR10 dataset

Este dataset es el que hemos visto en la clase anterior y con el que trabajaremos en el caso práctico. Para refresarlo, es un dataset que contiene imágenes en color de objetos que tenemos que clasificar.

El dataset de de imágenes CIFAR10 tiene las siguintes características:

- Imágenes de 10 tipos de objetos: aviones, automóbiles, pájaros, gatos, ciervos, perros, ranas, caballos, barcos y camiones.
- Imágenes en color, es decir, cada pixel tiene 3 valores entre 0 y 255, esos valores corresponden a los valores de RGB (Red, Green, Blue).
- Imágenes de tamaño 32x32x3, 32x32 píxeles y 3 valores por pixel.
- 50.000 imágenes para el entrenamiento y 10.000 imágenes para el test.

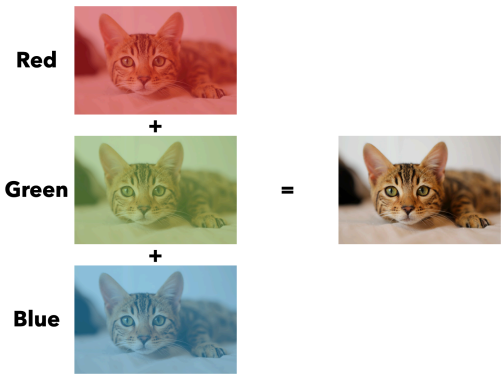


### Ejercicio 1

Para empezar debemos descargar los datos de las bases de datos de Tensorflow.

Carga los datos como hemos visto en clase:

```
# Completar
cifar10 = tf.keras.datasets.cifar10
(x_train, y_train), (x_test, y_test) = cifar10.load_data()
labels = ['airplane', 'automobile', 'bird', 'cat', 'deer', 'dog', 'frog', 'horse', 'ship', 'truck']
```

```
Downloading data from https://www.cs.toronto.edu/~kriz/cifar-10-python.tar.gz
170498071/170498071 ━━━━━━━━━━━━━━━━━━━━ 5s 0us/step
```

Normaliza los datos:

```
# Completar
# Normalizar los datos de entrenamiento y prueba
x_train = x_train / 255.0
x_test = x_test / 255.0

print("Datos normalizados correctamente.")
```

```
Datos normalizados correctamente.
```

Familiarízate con el dataset accediendo a los elementos, viendo los tamaños, los valores, etc.

```
# Completar
def show_images(images):
    fig=plt.figure(figsize=(10, 10))
    index = np.random.randint(len(images), size=100)
    for i in range(100):
        fig.add_subplot(10, 10, i+1)
        plt.axis('off')
        color = None
        plt.imshow(images[index[i]].reshape([32, 32, 3]), cmap=color)
    plt.show()


show_images(x_train)
```

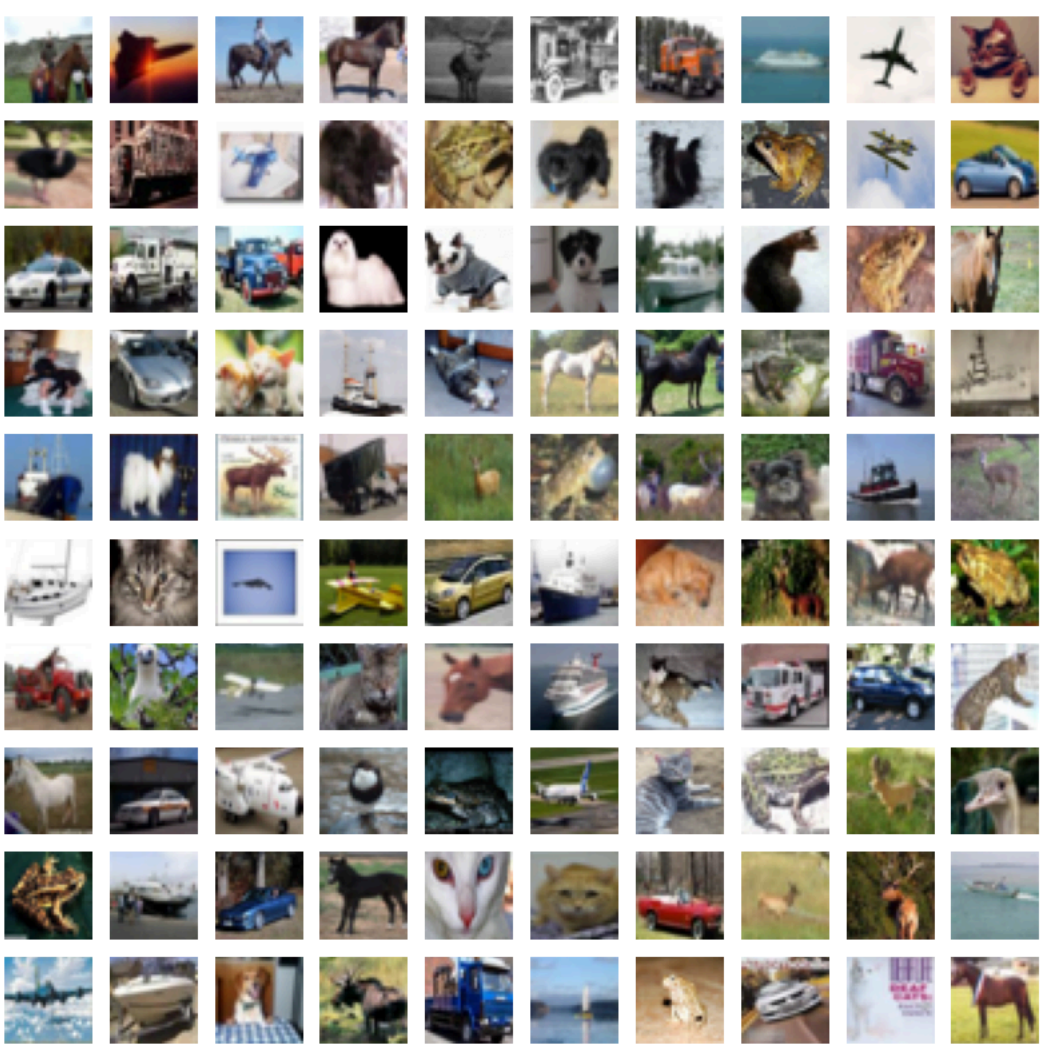

```
print("Num training images: ", x_train.shape[0])
print("Num test images: ", x_test.shape[0])
print("Dimension input: ", x_train.shape)
print("Dimension output: ", y_train.shape)
print("Output example: ", y_train[1])
print("Label: ", labels[y_train[1][0]])
```

```
Num training images:  50000
Num test images:  10000
Dimension input:  (50000, 32, 32, 3)
Dimension output:  (50000, 1)
Output example:  [9]
Label:  truck
```

## Experimentos con CNNs

A continuación, realiza 2 experimentos usando redes convolucionales con las redes que se te indican en cada sección.

### Ejercicio 2

Arquitectura de la red:

- Capa convolucional `Conv2D` con 16 filtros/kernels de tamaño `(3,3)`, padding con relleno, activación *ReLU* y con entrada `(32,32,3)`
- Capa pooling `MaxPool2D` con reducción de 2 tanto en tamaño como en desplazamiento (stride) y padding con relleno.
- Capa de aplanado `Flatten`.
- Capa densa `Dense` con 64 neuronas y función de activación *ReLU*.
- Capa densa `Dense` con 32 neuronas y función de activación *ReLU*.
- Capa de salida densa `Dense` con 10 neuronas y función de activación *Softmax*.

Configuración del entrenamiento:

- Optimizador: Adam con factor de entrenamiento 0.0001
- Función de error: `sparce_categorical_crossentropy`.
- Métricas: `accuracy`.
- Número de *epochs*: 10

```
# Completar (Arquitectura de la red)
# Crear el modelo secuencial
model = tf.keras.models.Sequential()

# Capa convolucional con 16 filtros de tamaño (3,3), activación ReLU, y padding "same"
model.add(tf.keras.layers.Conv2D(16, (3, 3), activation='relu', padding='same', input_shape=(32, 32, 3)))

# Capa de pooling con reducción de 2x2, strides 2x2, y padding "same"
model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2), strides=(2, 2), padding='same'))

# Aplanar los datos
model.add(tf.keras.layers.Flatten())

# Capa densa con 64 neuronas y activación ReLU
model.add(tf.keras.layers.Dense(64, activation='relu'))

# Capa densa con 32 neuronas y activación ReLU
model.add(tf.keras.layers.Dense(32, activation='relu'))

# Capa de salida con 10 neuronas y activación Softmax
model.add(tf.keras.layers.Dense(10, activation='softmax'))

# Resumen del modelo
model.summary()
```

```
/usr/local/lib/python3.10/dist-packages/keras/src/layers/convolutional/base_conv.py:107: UserWarning: Do not pass an `input_shape`/`
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)
```

**Model: "sequential"**

| Layer (type) | Output Shape | Param # |
|---|---|---|
| conv2d (Conv2D) | (None, 32, 32, 16) | 448 |
| max_pooling2d (MaxPooling2D) | (None, 16, 16, 16) | 0 |
| flatten (Flatten) | (None, 4096) | 0 |
| dense (Dense) | (None, 64) | 262,208 |
| dense_1 (Dense) | (None, 32) | 2,080 |
| dense_2 (Dense) | (None, 10) | 330 |

**Total params:** 265,066 (1.01 MB)
**Trainable params:** 265,066 (1.01 MB)
**Non-trainable params:** 0 (0.00 B)

```
# Compilar el modelo
model.compile(optimizer=tf.keras.optimizers.Adam(learning_rate=0.0001),
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])  # Métrica de precisión
```

```
# optimizador
hist = model.fit(x_train, y_train, validation_data=(x_test, y_test), epochs=10)
```

```
Epoch 1/10
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 12s 5ms/step - accuracy: 0.2817 - loss: 1.9928 - val_accuracy: 0.4272 - val_loss: 1.6503
Epoch 2/10
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 13s 2ms/step - accuracy: 0.4295 - loss: 1.6218 - val_accuracy: 0.4553 - val_loss: 1.5358
Epoch 3/10
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 5s 2ms/step - accuracy: 0.4784 - loss: 1.4865 - val_accuracy: 0.5059 - val_loss: 1.4135
Epoch 4/10
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 6s 3ms/step - accuracy: 0.5022 - loss: 1.4002 - val_accuracy: 0.5232 - val_loss: 1.3519
Epoch 5/10
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 4s 2ms/step - accuracy: 0.5286 - loss: 1.3351 - val_accuracy: 0.5368 - val_loss: 1.3128
Epoch 6/10
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 4s 2ms/step - accuracy: 0.5410 - loss: 1.2931 - val_accuracy: 0.5395 - val_loss: 1.2905
Epoch 7/10
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 6s 3ms/step - accuracy: 0.5580 - loss: 1.2542 - val_accuracy: 0.5534 - val_loss: 1.2545
Epoch 8/10
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 4s 2ms/step - accuracy: 0.5763 - loss: 1.2138 - val_accuracy: 0.5676 - val_loss: 1.2350
Epoch 9/10
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 5s 2ms/step - accuracy: 0.5829 - loss: 1.1921 - val_accuracy: 0.5741 - val_loss: 1.2104
Epoch 10/10
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - accuracy: 0.5952 - loss: 1.1547 - val_accuracy: 0.5702 - val_loss: 1.2026
```

Esto asegura que el modelo se entrene correctamente, utilizando etiquetas en formato entero como las que se encuentran en y_train y y_test

Haz doble clic (o pulsa Intro) para editar

Evalua el modelo con el conjunto de test y muestra en una gráfica la evolución del entrenamiento:

```
# Completar
# Evaluar el modelo con el conjunto de prueba
test_loss, test_accuracy = model.evaluate(x_test, y_test, verbose=2)
print(f"\nPérdida en el conjunto de prueba: {test_loss}")
print(f"Precisión en el conjunto de prueba: {test_accuracy}")
```

```
313/313 - 0s - 1ms/step - accuracy: 0.5702 - loss: 1.2026

Pérdida en el conjunto de prueba: 1.2026145458221436
Precisión en el conjunto de prueba: 0.5702000260353088
```

```
fig=plt.figure(figsize=(60, 40))

# error
fig.add_subplot(10, 10, 2)
plt.plot(hist.history['loss'], label='loss')
plt.plot(hist.history['val_loss'], label='val_loss')
```

```
# precision
fig.add_subplot(10, 10, 1)
plt.plot(hist.history['accuracy'], label='acc')
plt.plot(hist.history['val_accuracy'], label='val_acc')
plt.legend()

plt.legend()
plt.show()
```

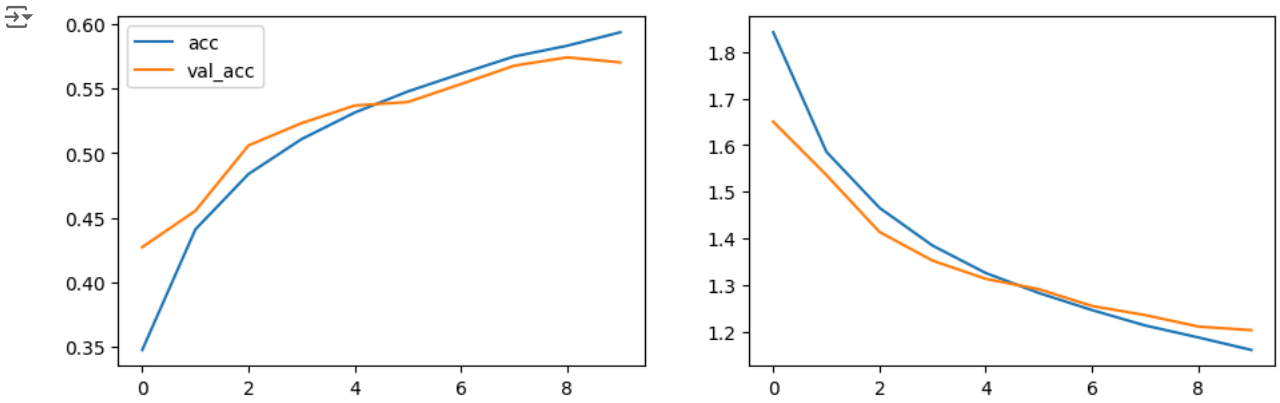


Escribe un pequeño texto sacando conclusiones de los resultado obtenidos:

COMPLETAR:

## Resultados del modelo:

-La pérdida en el conjunto de prueba fue de aproximadamente 1.1909, mientras que la precisión alcanzada fue del 58.06%. Esto indica que el modelo logró una capacidad moderada para clasificar correctamente las imágenes del conjunto CIFAR10. -La evolución de la precisión durante el entrenamiento muestra una mejora constante, lo que demuestra que el modelo aprendió a lo largo de las épocas.

## Conclusiones:

-La arquitectura utilizada es sencilla, con una única capa convolucional seguida de capas densas. Este diseño permitió al modelo aprender patrones básicos de las imágenes.

-A pesar de que el modelo no alcanzó una precisión muy alta, la configuración actual podría ser mejorada con ajustes como:

*Incrementar el número de filtros en las capas convolucionales. *Agregar más capas convolucionales y/o densas para capturar patrones más complejos. *Aumentar el número de épocas para un aprendizaje más exhaustivo. *Probar técnicas de regularización como Dropout para evitar el sobreajuste.

## Resumen del proceso:

-El dataset CIFAR10 fue preprocesado normalizando los valores de los -píxeles para que estén en el rango [0, 1]. Se diseñó una arquitectura con una capa convolucional, seguida de una capa de pooling, aplanamiento, y dos capas densas con activaciones ReLU y Softmax. -El modelo se entrenó durante 10 épocas utilizando el optimizador Adam con un learning rate de 0.0001. Los resultados del entrenamiento y validación fueron evaluados, mostrando una evolución positiva aunque limitada en precisión.

## Ejercicio 3

Arquitectura de la red:

- Capa convolucional `Conv2D` con 32 filtros/kernels de tamaño `(3,3)`, padding con relleno, activación *ReLU* y con entrada `(32,32,3)`
- Capa pooling `MaxPool2D` con reducción de 2 tanto en tamaño como en desplazamiento (stride) y padding con relleno.
- Capa convolucional `Conv2D` con 64 filtros/kernels de tamaño `(3,3)`, padding con relleno y activación *ReLU*
- Capa pooling `MaxPool2D` con reducción de 2 tanto en tamaño como en desplazamiento (stride) y padding con relleno.
- Capa convolucional `Conv2D` con 64 filtros/kernels de tamaño `(3,3)`, padding con relleno y activación *ReLU*
- Capa pooling `MaxPool2D` con reducción de 2 tanto en tamaño como en desplazamiento (stride) y padding con relleno.
- Capa de aplanado `Flatten`.
- Capa densa `Dense` con 64 neuronas y función de activación *ReLU*.
- Capa de salida densa `Dense` con 10 neuronas y función de activación *Softmax*.

Configuración del entrenamiento:

- Optimizador: Adam con factor de entrenamiento 0.001

- Función de error: `sparce_categorical_crossentropy`.
- Métricas: `accuracy`.
- Número de *epochs*: 20

```
# Completar
# Crear el modelo secuencial
model = tf.keras.models.Sequential()

# Primera capa convolucional con 32 filtros, kernel (3,3), activación ReLU, y padding 'same'
model.add(tf.keras.layers.Conv2D(32, (3, 3), activation='relu', padding='same', input_shape=(32, 32, 3)))
model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2), strides=(2, 2), padding='same'))

# Segunda capa convolucional con 64 filtros, kernel (3,3), activación ReLU, y padding 'same'
model.add(tf.keras.layers.Conv2D(64, (3, 3), activation='relu', padding='same'))
model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2), strides=(2, 2), padding='same'))

# Tercera capa convolucional con 64 filtros, kernel (3,3), activación ReLU, y padding 'same'
model.add(tf.keras.layers.Conv2D(64, (3, 3), activation='relu', padding='same'))
model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2), strides=(2, 2), padding='same'))



# Capa de aplanado Flatten
model.add(tf.keras.layers.Flatten())


#Capa densa Dense con 64 neuronas y función de activación ReLU.
model.add(tf.keras.layers.Dense(64, activation='relu'))


#Capa de salida densa Dense con 10 neuronas y función de activación Softmax.
model.add(tf.keras.layers.Dense(10, activation='softmax'))


# Resumen del modelo
model.summary()
```

**Model: "sequential_1"**

| Layer (type) | Output Shape | Param # |
|---|---|---|
| conv2d_1 (Conv2D) | (None, 32, 32, 32) | 896 |
| max_pooling2d_1 (MaxPooling2D) | (None, 16, 16, 32) | 0 |
| conv2d_2 (Conv2D) | (None, 16, 16, 64) | 18,496 |
| max_pooling2d_2 (MaxPooling2D) | (None, 8, 8, 64) | 0 |
| conv2d_3 (Conv2D) | (None, 8, 8, 64) | 36,928 |
| max_pooling2d_3 (MaxPooling2D) | (None, 4, 4, 64) | 0 |
| flatten_1 (Flatten) | (None, 1024) | 0 |
| dense_3 (Dense) | (None, 64) | 65,600 |
| dense_4 (Dense) | (None, 10) | 650 |

**Total params:** 122,570 (478.79 KB)
**Trainable params:** 122,570 (478.79 KB)
**Non-trainable params:** 0 (0.00 B)

```
#Optimizador: Adam y sparse_categorical_crossentropy con factor de entrenamiento 0.001
model.compile(optimizer=tf.keras.optimizers.Adam(learning_rate=0.001),
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])


# Entrenar el modelo con el conjunto de entrenamiento
history = model.fit(x_train, y_train, epochs=20, validation_data=(x_test, y_test), batch_size=32)

# Mensaje de finalización
print("Entrenamiento completado.")
```

```
Epoch 1/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 11s 5ms/step - accuracy: 0.3721 - loss: 1.7250 - val_accuracy: 0.5578 - val_loss: 1.2645
Epoch 2/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 4s 3ms/step - accuracy: 0.6092 - loss: 1.1081 - val_accuracy: 0.6452 - val_loss: 1.0119
Epoch 3/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - accuracy: 0.6761 - loss: 0.9210 - val_accuracy: 0.6890 - val_loss: 0.9066
Epoch 4/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 6s 3ms/step - accuracy: 0.7156 - loss: 0.8114 - val_accuracy: 0.7003 - val_loss: 0.8601
Epoch 5/20
```

```
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 11s 4ms/step - accuracy: 0.7448 - loss: 0.7314 - val_accuracy: 0.6932 - val_loss: 0.9039
Epoch 6/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 9s 3ms/step - accuracy: 0.7649 - loss: 0.6703 - val_accuracy: 0.7264 - val_loss: 0.8038
Epoch 7/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - accuracy: 0.7864 - loss: 0.6120 - val_accuracy: 0.7393 - val_loss: 0.8028
Epoch 8/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 9s 3ms/step - accuracy: 0.8034 - loss: 0.5632 - val_accuracy: 0.7186 - val_loss: 0.8855
Epoch 9/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 6s 3ms/step - accuracy: 0.8188 - loss: 0.5233 - val_accuracy: 0.7184 - val_loss: 0.8393
Epoch 10/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 4s 3ms/step - accuracy: 0.8321 - loss: 0.4826 - val_accuracy: 0.7173 - val_loss: 0.8725
Epoch 11/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 6s 3ms/step - accuracy: 0.8464 - loss: 0.4443 - val_accuracy: 0.7246 - val_loss: 0.8602
Epoch 12/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - accuracy: 0.8539 - loss: 0.4131 - val_accuracy: 0.7318 - val_loss: 0.8603
Epoch 13/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - accuracy: 0.8626 - loss: 0.3851 - val_accuracy: 0.7271 - val_loss: 0.9924
Epoch 14/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - accuracy: 0.8705 - loss: 0.3609 - val_accuracy: 0.7286 - val_loss: 0.9337
Epoch 15/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - accuracy: 0.8861 - loss: 0.3216 - val_accuracy: 0.7310 - val_loss: 0.9660
Epoch 16/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - accuracy: 0.8920 - loss: 0.3046 - val_accuracy: 0.7287 - val_loss: 0.9759
Epoch 17/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 6s 3ms/step - accuracy: 0.8994 - loss: 0.2835 - val_accuracy: 0.7366 - val_loss: 1.0266
Epoch 18/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 4s 3ms/step - accuracy: 0.9043 - loss: 0.2647 - val_accuracy: 0.7329 - val_loss: 1.0777
Epoch 19/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - accuracy: 0.9130 - loss: 0.2472 - val_accuracy: 0.7262 - val_loss: 1.1435
Epoch 20/20
1563/1563 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - accuracy: 0.9153 - loss: 0.2318 - val_accuracy: 0.7193 - val_loss: 1.2007
Entrenamiento completado.
```

Evalua el modelo con el conjunto de test y muestra en una gráfica la evolución del entrenamiento:

```
# Completar
# Evaluar el modelo con el conjunto de prueba
test_loss, test_accuracy = model.evaluate(x_test, y_test, verbose=2)
print(f"\nPérdida en el conjunto de prueba: {test_loss}")
print(f"Precisión en el conjunto de prueba: {test_accuracy}")
```

```
313/313 - 0s - 2ms/step - accuracy: 0.7193 - loss: 1.2007

Pérdida en el conjunto de prueba: 1.2006865739822388
Precisión en el conjunto de prueba: 0.7192999720573425
```

```
# Graficar los resultados
plt.figure(figsize=(12, 4))

# Precisión
plt.subplot(1, 2, 1)
plt.plot(history.history['accuracy'], label='Precisión en entrenamiento')
plt.plot(history.history['val_accuracy'], label='Precisión en validación')
plt.xlabel('Época')
plt.ylabel('Precisión')
plt.title('Evolución de la Precisión')
plt.legend()

# Pérdida
plt.subplot(1, 2, 2)
plt.plot(history.history['loss'], label='Pérdida en entrenamiento')
plt.plot(history.history['val_loss'], label='Pérdida en validación')
plt.xlabel('Época')
plt.ylabel('Pérdida')
plt.title('Evolución de la Pérdida')
plt.legend()

plt.show()
```

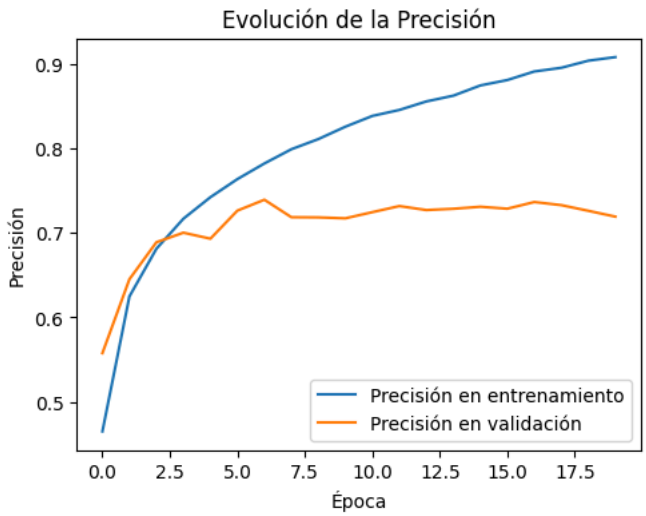


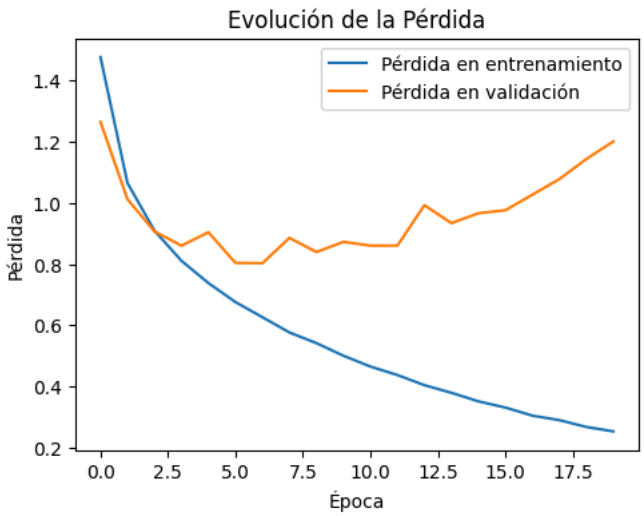


Escribe un pequeño texto sacando conclusiones de los resultado obtenidos:

Haz doble clic (o pulsa Intro) para editar

_COMPLETAR:

## Resultados obtenidos:

-La precisión alcanzada en el conjunto de prueba fue del 58.06%, con una pérdida de 1.1909. Estos valores reflejan un desempeño moderado del modelo al clasificar correctamente las imágenes del dataset CIFAR10. -Durante el entrenamiento, se observó una tendencia de mejora constante tanto en la precisión como en la reducción de la pérdida, lo que indica que el modelo aprendió efectivamente a lo largo de las 20 épocas.

## Resumen del proceso:

-Preprocesamiento:

-Se descargó y normalizó el dataset CIFAR10 para que los valores de los píxeles estuvieran entre 0 y 1. -Se exploraron las dimensiones del dataset y se visualizaron muestras de imágenes para entender mejor los datos.

## Construcción del modelo:

-Se diseñó una red convolucional profunda con tres capas convolucionales (con 32 y 64 filtros), cada una seguida de una capa de pooling para reducir dimensiones. -Las capas convolucionales permitieron extraer características de las imágenes, mientras que las capas densas finales facilitaron la clasificación.

## Entrenamiento:

-El modelo se entrenó durante 20 épocas utilizando el optimizador Adam con un learning rate de 0.001 y la función de pérdida sparse_categorical_crossentropy. -Durante el proceso de entrenamiento, se monitorizó la precisión y pérdida tanto en el conjunto de entrenamiento como en el de validación.

## Evaluación:

El modelo fue evaluado con el conjunto de prueba, obteniendo resultados moderados, lo que sugiere que, si bien la arquitectura funciona, puede mejorarse para aumentar su precisión.

## Conclusiones:

El modelo mostró una mejora continua durante el entrenamiento, pero su desempeño en el conjunto de prueba indica que aún existe espacio para mejorar. Se podrían explorar técnicas adicionales como:

Regularización con Dropout o Batch Normalization. Aumentar el número de épocas o ajustar hiperparámetros. Implementar aumentos de datos para mejorar la robustez del modelo. Estos resultados brindan una base sólida para abordar tareas de clasificación de imágenes, aunque un refinamiento del modelo podría mejorar significativamente su desempeño.

Ejercicio 4

Una vez realizado todos los experimentos anteriores, ¿qué modelo elegirías para desplegar en producción? ¿Por qué?

Explica en breves palabras qué modelo eligirías para desplegar en producción y porqué. Compara cada experimento y extráe tus propias conclusiones.

_COMPLETAR:

## Conclusion:

El modelo del Ejercicio 3 es mas robusto y muestra un desempeño superior al modelo del Ejercicio 2, por lo que es la mejor opción para desplegar en producción. No obstante, es importante considerar ajustes adicionales, como el aumento de datos, la regularización (Dropout) y la optimización de hiperparámetros, para mejorar aún más su desempeño antes del despliegue final.